

小样本下的自适应学习策略研究

2018年12月06日

目录

•目前需求

•实验进展

•实验计划



目前需求

大纪元数据(2万条): 负样本比较多, 占70%左右,目标是把负样本挑出来

人民日报数据(2483条):作为正样本



- 正面样本2138条(有效)
- 负面样本20000条(有效)
- 模型一训练集4000条(正面负面各2000条)
- 模型二训练集169条(69条正面样本100条负面样本)
- 模型二测试集169条(69条正面样本100条负面样本)



数据格式:

• 模型一: Context:"新闻正文数据", Label:"0/1" (0表示负面, 1表示正面)

```
{"id": "1", "words": ["新", "唐人", "电视台", "将", "在", "感恩节", "期间", "播出",
                              - "2018", "年", "11", "月", "14", "日讯退", "团队", "声明", "认清", "中共
{"id": "8", "words": ["图为", "蒙华", "铁路", "汉江", "特", "大桥", "。", "金", " ", "伟摄", "(",
```

TONGJI UNIVERSITY

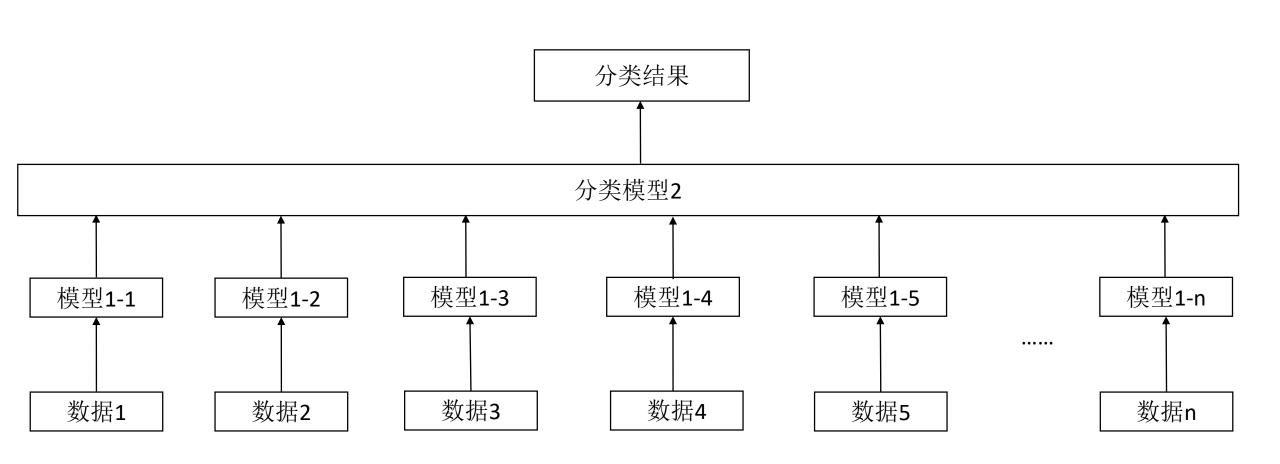
数据格式:

• 模型二:

```
test2, test3, test4, test5, test6, test7, test8, test9
0,0,0,0,0,0,0,0,1,0,0
```

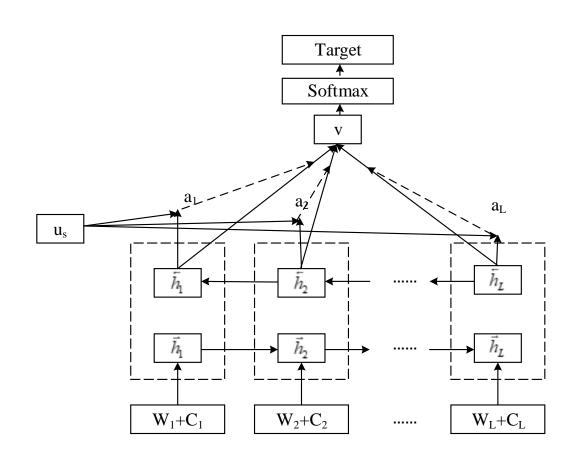


实验设计:整体结构

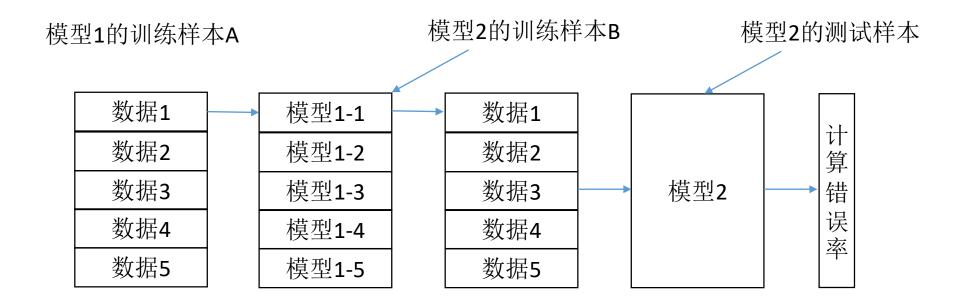




实验设计:模型一结构









实验结果: 5个模型

每个模型的输入数据:

模型一数据集: 40000/5=8000条 (训练集6400,测试集1600)

模型二数据集: 169条 (训练集136,测试集33)

模型测试数据: 169条

测试集五次测试集结果:

第一次实验错误率:

0.4082

0.4082

0.0000

0.0000

0.0000

第二次实验 错误率:

0.0237

0.0059

0.0059

0.0059

0.0059



实验结果: 10个模型

每个模型的输入数据:

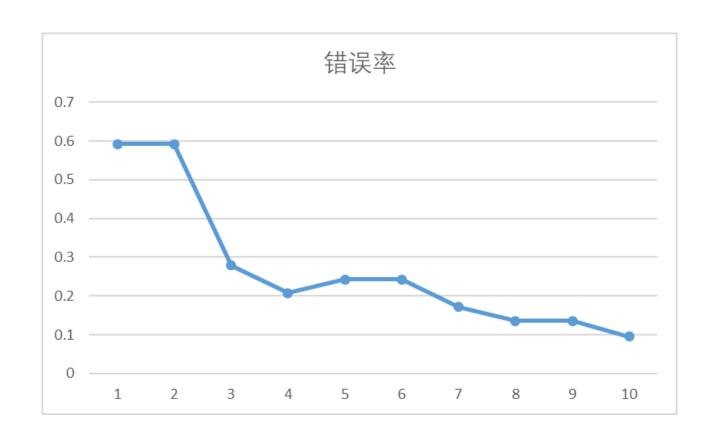
模型一数据集: 40000/10=4000条 (训练集3200,测试集800)

模型二数据集: 169条 (训练集136,测试集33)

模型测试数据: 169条



实验结果: 10个模型



测试集十次测试集结果:

0.5917

0.5917

0.2781

0.2071

0.2426

0.2426

0.2.20

0.1716

0.1360

0.1360

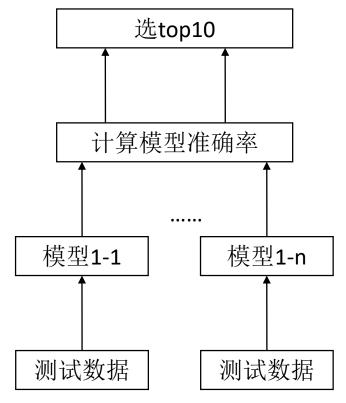
0.0946

全部的0.0313



实验计划

1. 筛选model1模型



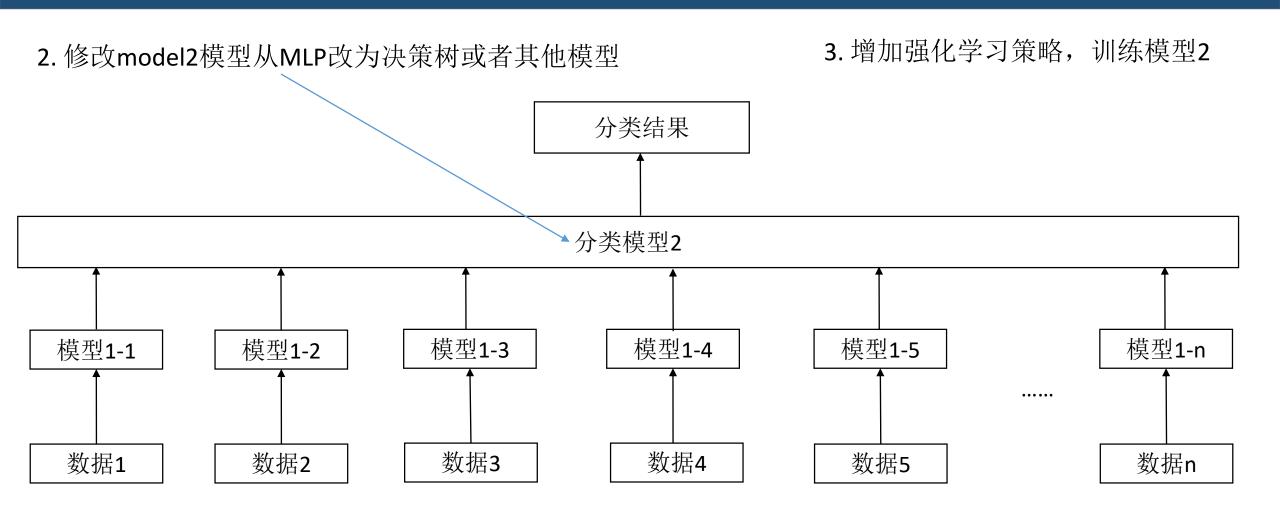
相似度较大取其1 计算模型分类结果的相似性 • • • • • • 模型1-1 模型1-n 测试数据 测试数据

根据得分进行筛选

根据结果的相似性进行筛选



实验计划



TONGJI UNIVERSITY



谢谢! 0_0

2018年12月06日